

# Montecarlo por cadenas de Markov

## Algoritmo de Metropolis-Hastings

objetivo

El objetivo del *algoritmo de Metropolis-Hastings* es construir una cadena de Markov que tenga como distribución invariante una distribución con una función de densidad f específica. Para ello, una vez elegida una distribución condicional con función de densidad  $q(y | x)$ , establece la distribución de transición de la cadena de Markov como sigue:

Dado el estado actual  $x_t$

1. Proponer un nuevo estado  $y$  según la densidad instrumental  $q(\cdot | x_t)$ .
2. Calcular la razón de Hastings

de donde sale?

$$r(y | x_t) = \frac{f(y)q(x_t | y)}{f(x_t)q(y | x_t)}$$

queremos la  
propiedad de  
balance detallado  
con f

3. Aceptar el nuevo estado  $y$  con probabilidad  $a(y | x_t) = \min(1, r(y | x_t))$ .

Es decir,

$$x_{t+1} = \begin{cases} y & \text{con probabilidad } a(y | x_t), \\ x_t & \text{con probabilidad } 1 - a(y | x_t). \end{cases}$$

para obtener una probabilidad

Observaciones:

↳ si no lo acepto  $x_{t+1} = x_t$ , no esperamos de  
generar un nuevo

- Basta conocer una versión no normalizada de  $f$ . En efecto, si  $f = cf_u$ , entonces hasta que

podemos conocer  $f$  salvo una const.  $r(y | x_t) = \frac{f(y)q(x_t | y)}{f(x_t)q(y | x_t)} = \frac{cf_u(y)q(x_t | y)}{cf_u(x_t)q(y | x_t)} = \frac{f_u(y)q(x_t | y)}{f_u(x_t)q(y | x_t)}$   
multiplicativo

↳ se anulan

- El estado inicial  $x_0$  debe ser tal que  $f(x_0) > 0$ . En caso contrario,  $r(y | x_0)$  no estaría bien definido.

- Asumiendo  $f(x_0) > 0$ , se tiene que  $f(x_t) > 0$  y  $r(y | x_t)$  está bien definido para todo  $t \in \mathbb{Z}_{\geq 0}$ . En efecto, dado  $f(x_t) > 0$ , sea  $y$  el estado propuesto para  $x_{t+1}$ . Entonces debe ser  $q(y | x_t) > 0$  y el denominador de la razón de Hastings es mayor que 0. Por otra parte, si  $f(y) = 0$  la razón de Hastings es 0, por lo que se rechaza con probabilidad 1 el estado propuesto y  $x_{t+1} = x_t$ . En consecuencia,  $f(x_{t+1}) > 0$  en cualquier caso.

1 de 2

• INVARIANCIA : consecuencia de  
(2) ↗ BALANCE  
DETALLADO

• IRREDUCIBILIDAD :  
depende de la elección  
de q

## Muestreador de Gibbs

El *muestreador de Gibbs* es otro algoritmo para construir una cadena de Markov que tenga como distribución invariante una distribución con una función de densidad multi-dimensional  $f(x_1, \dots, x_d)$  específica. Aunque su origen es independiente, posteriormente se demostró que es un caso particular del algoritmo de Metropolis-Hastings.

Asumiendo que es sencillo generar valores aleatorios de las *densidades condicionales completas*  $f_i(x_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d)$ , el algoritmo establece la distribución de transición de la cadena de Markov como sigue:

Dado el estado actual  $\mathbf{x}_t = (x_{1t}, \dots, x_{dt})$

1. Generar  $x_{1t+1} \sim f_1(\cdot | x_{2t}, \dots, x_{dt})$ .
2. Generar  $x_{2t+1} \sim f_2(\cdot | x_{1t+1}, x_{3t}, \dots, x_{dt})$ .
- $\vdots$
- d. Generar  $x_{dt+1} \sim f_d(\cdot | x_{1t+1}, \dots, x_{d-1t+1})$ .

Entonces  $\mathbf{x}_{t+1} = (x_{1t+1}, \dots, x_{dt+1})$ .

MC por cadenas de Markov

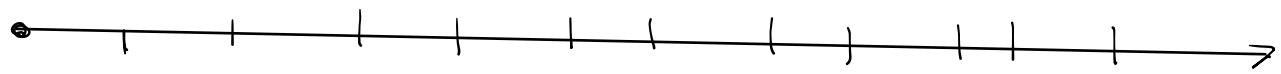
$$\hat{w} = \frac{1}{n} \sum_{t=1}^n g(X_t) \quad X_1, \dots, X_t \text{ realización de la cadena}$$

$$\begin{aligned} \text{Var}(\hat{w}) &= \frac{1}{n^2} \sum_{t_1, t_2=1}^n \text{Cov}(g(X_{t_1}), g(X_{t_2})) \\ &= \frac{\text{Var}(g(X))}{n} + \boxed{\sum_{t_1 \neq t_2} \text{Cov}(g(X_{t_1}), g(X_{t_2}))} \end{aligned}$$

2 de 2

additional term

# Partición en lotes (BATCHES)



$n$ : estados totales

$b$ : numero lotes

$$m = \frac{n}{b} \quad \text{tamaño de los lotes}$$

$$\forall i=1, \dots, b$$

Por lote el  $i$ -esimo lote:

$$X_{(i-1)m+1}, \dots, X_{im} : \hat{w}_i = \frac{1}{m} \sum_{t=(i-1)m+1}^{im} g(X_t)$$

→ Obtenemos  $b$  valores de  $\hat{w}_1, \dots, \hat{w}_b$

⇒ más o menos independientes cuando mayor sea el tamaño  $m$  de los lotes

$$\text{Al final : } \hat{w} = \frac{1}{b} \cdot \frac{1}{m} \sum_{i=1}^b \sum_{t=(i-1)m+1}^{im} g(X_t)$$

$$I = \frac{1}{n} \sum_{t=1}^n g(x_t)$$

(~ algoritmo MC con b valores en este caso)

- Queremos:
- Alto numero de lobes  $k$
  - Alto numero promedio de lobes  $m$

Pero estos dos son en contradiccion  
si  $n$  es fijado

## Muestreador de Gibbs

El muestreador de Gibbs es otro algoritmo para construir una cadena de Markov que tenga como distribución invariante una distribución con una función de densidad multi-dimensional  $f(x_1, \dots, x_d)$  específica. Aunque su origen es independiente, posteriormente se demostró que es un caso particular del algoritmo de Metropolis-Hastings.

Asumiendo que es sencillo generar valores aleatorios de las *densidades condicionales completas*  $f_i(x_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d)$ , el algoritmo establece la distribución de transición de la cadena de Markov como sigue:

Dado el estado actual  $\mathbf{x}_t = (x_{1t}, \dots, x_{dt})$

1. Generar  $x_{1t+1} \sim f_1(\cdot | x_{2t}, \dots, x_{dt})$ .
2. Generar  $x_{2t+1} \sim f_2(\cdot | \underline{x_{1t+1}}, x_{3t}, \dots, x_{dt})$ .
- :  
*actualizado*
- d. Generar  $x_{dt+1} \sim f_d(\cdot | x_{1t+1}, \dots, \underline{x_{d-1t+1}})$ .

Entonces  $\mathbf{x}_{t+1} = (x_{1t+1}, \dots, x_{dt+1})$ .

componentes  
del vector

objetivo: generar valores aleatorios según una  
densidad multidimensional  $f(x_1, \dots, x_d)$   
con  $d > 1$

requisitos: saber generar valores aleatorios de las  
distribuciones condicionales completas, es  
decir, según las densidades  $f_i(x_i | x_1, \dots, x_{i-1})$   
 $x_{i+1}, \dots, x_d$

la dificultad es  
determinar estas  
distribuciones

